

MIMO-Kanalschätzung für mmWave basierend auf Deep-Learning mit Außerbandinformation

Faruk Pasic*, Philipp Svoboda*[†] and Christoph F. Mecklenbräuer*

*Institut für Nachrichtentechnik, TU Wien

[†]Christian Doppler Laboratory for Digital Twin assisted AI for sustainable Radio Access Networks

faruk.pasic@tuwien.ac.at

Kurzfassung—Künftige drahtlose Multiple-Input Multiple-Output (MIMO)-Systeme werden sowohl Frequenzbänder unter 6 GHz als auch Millimeterwellen (mmWave) integrieren, um den steigenden Anforderungen an hohe Datenraten gerecht zu werden. Der Aufbau von MIMO-Verbindungen erfordert in der Regel eine präzise Kanalschätzung, die bei mmWave-Frequenzen aufgrund des geringen Signal-Rausch-Verhältnis (SNR) eine besondere Herausforderung darstellt. In dieser Arbeit schlagen wir eine neuartige Deep-Learning-basierte Methode zur Schätzung von mmWave-MIMO-Kanälen vor, die Außerbandinformationen aus dem Sub-6-GHz-Band einbezieht. Unsere Methode basiert auf einer Convolutional Neural Network (CNN)-Architektur und wird sowohl mit Deep-Learning-Ansätzen verglichen, die ausschließlich auf In-Band-Informationen basieren, als auch mit anderen Außerband-gestützten Verfahren. Die Simulationsergebnisse zeigen, dass die vorgeschlagene Deep-Learning-Methode mit Außerband-Unterstützung bestehende Alternativen hinsichtlich des mittleren quadratischen Kanalfehlers (mittlere quadratische Kanalfehler (MSE)) übertrifft.

Indexbegriffe—Kanalschätzung, Deep-Learning, mmWave, MIMO, CNN.

I. EINLEITUNG

Die zunehmende Verbreitung datenintensiver Anwendungen wie Augmented Reality, Virtual Reality, autonome Systeme und Industrieautomatisierung hat den Bedarf an hochbandbreitiger Kommunikation erheblich gesteigert. Mobile Edge-Computing (MEC) hat sich als ein Schlüsselparadigma zur Bewältigung dieser Herausforderungen herauskristallisiert, indem es Rechenressourcen näher an die Endnutzer bringt und die Belastung der Kernnetze reduziert. Die Effektivität von MEC wird jedoch grundsätzlich durch die Kapazität der zugrunde liegenden drahtlosen Infrastruktur eingeschränkt.

Die Millimeterwellen-Kommunikation hat aufgrund ihrer großen Bandbreite das Potenzial, hohe Datenraten zu erreichen [1], [2]. Um die hohen Ausbreitungsverluste zu kompensieren und eine stabile Verbindung sicherzustellen, werden in den meisten Millimeterwellen (mmWave)-Systemen große Antennenarrays und Multiple-Input Multiple-Output (MIMO)-Techniken eingesetzt. Die größte Herausforderung bei der Implementierung von mmWave-MIMO-Systemen liegt im Verbindungsaufbau, der eine präzise Kanalschätzung erfordert. Allerdings gestaltet sich die Kanalschätzung bei mmWave-Frequenzen besonders schwierig, da das Signal-Rausch-Verhältnis (SNR) vor der Strahlformung in der Regel sehr niedrig ist.

In letzter Zeit haben maschinelle Lernverfahren (ML)-Techniken, insbesondere Deep-Learning-Methoden auf Basis mehrschichtiger Perceptrons, große Aufmerksamkeit für die mmWave-MIMO-Kanalschätzung erregt [3], [4]. Zudem werden mmWave-Systeme zunehmend in Kombination mit Sub-6-GHz-Systemen eingesetzt, um die Multibandkommunikation zu ermöglichen [5]. Systeme im Sub-6-GHz-Bereich weisen geringere Ausbreitungsverluste auf, was zu einem höheren SNR vor der Strahlformung führt [6]. Diese zuverlässigen Außerbandinformationen aus dem Sub-6-GHz-Bereich können zur Unterstützung und Verbesserung der Kanalschätzung in mmWave-Systemen genutzt werden [7]. Die Verwendung von Außerbandinformationen für die mmWave-Kanalschätzung wurde in [8] untersucht. Dabei werden neuartige pilot-gestützte Kanalschätzungsmethoden für mmWave-MIMO-Systeme vorgeschlagen, die die durch das Sub-6-GHz-Band gewonnene line-of-sight (LOS)-Kanalkomponente ausnutzen. Allerdings bleiben ohne den Einsatz von ML viele inhärente Zusammenhänge zwischen In-Band- und Außerband-Kanalschätzungen ungenutzt.

In dieser Arbeit erweitern wir die Außerband-gestützten Kanalschätzungsmethoden aus [8] durch den Einsatz von ML. Im Gegensatz zu konventionellen Methoden hat ML eine größere Kapazität, die intrinsischen Beziehungen zwischen In-Band- und Außerband-Kanalschätzungen aufzudecken. Wir schlagen eine neuartige Methode für mmWave MIMO-Systeme vor, die auf einer CNN-Architektur basiert. Die Leistungsfähigkeit der vorgeschlagenen Methode evaluieren wir anhand von Simulationen, wobei der normalisierte mittlere quadratische Kanalfehler (MSE) als Bewertungsmetrik dient.

II. VERBINDUNGSaufbau

Wir betrachten ein Punkt-zu-Punkt-MIMO-System, das gleichzeitig auf Sub-6-GHz- und mmWave-Frequenzbändern arbeitet. Beide Antennenarrays - sowohl für Sub-6-GHz als auch für mmWave - sind als Uniform Linear Array (ULA) angeordnet, gemeinsam positioniert und ausgerichtet, um identische Angle-of-Departure (AoD) und Angle-of-Arrival (AoA) für beide Frequenzbereiche sicherzustellen. Wir setzen eine perfekte Synchronisation zwischen Sender und Empfänger sowohl im Zeit- als auch im Frequenzbereich voraus. Jeder Sender und Empfänger ist mit einer einzigen Hochfrequenzkette pro Antenne ausgestattet, wodurch eine vollständig digitale Strahlformung sowohl im Sub-6-GHz- als auch im mmWave-




Fig. 1. Die CNN-Architektur umfasst neun Faltungsschichten, gefolgt von einer Ausgabeschicht, die die geschätzte Kanalmatrix erzeugt.

Frequenzband ermöglicht wird. Das System arbeitet im Time-Division Duplex (TDD)-Modus, wodurch die Reziprozität des Kanals gewährleistet wird. Als Übertragungsverfahren kommt Orthogonal Frequency-Division Multiplexing (OFDM) zum Einsatz.

Der Verbindungsaufbau umfasst eine Trainingsphase, gefolgt von der Datenübertragung. Während der Trainingsphase wird der Kanal sowohl im Sub-6-GHz- als auch im mmWave-Frequenzband geschätzt. Die daraus gewonnenen Kanalschätzungen werden anschließend kombiniert und für die Datenübertragung über das mmWave-Band genutzt.

A. Trainingsphase

Die Trainingsphase erfolgt in zwei aufeinanderfolgenden Schritten.

1) *Erster Schritt:* Zunächst werden nicht-vorcodierte Pilotsymbole über beide Frequenzbänder ausgesendet [9]. Am Empfänger wird der Kanal für beide Bänder mithilfe der Least-Squares (LS)-Methode geschätzt und anschließend durch lineare Interpolation weiterverarbeitet. Damit eine optimale Auswahl der Strahlformungsmatrix möglich ist, muss die am Empfänger ermittelte Kanalschätzung auch dem Sender zur Verfügung stehen. Da das System im TDD-Modus arbeitet, wird die Reziprozität der Kanäle in beiden Frequenzbändern genutzt, um die Erfassung der Kanalschätzung am Sender zu ermöglichen.

2) *Zweiter Schritt:* Die Kanalschätzung im Sub-6-GHz-Band wird zur gemeinsamen Schätzung des AoA und AoD der LOS-Komponente verwendet, basierend auf der in [8] beschriebenen Methode. Unter Verwendung dieser geschätzten Winkelinformationen werden vorcodierte/kombinierte Pilotsymbole in Richtung der LOS-Komponente gesendet - jedoch ausschließlich im mmWave-Band. Daraufhin erfolgt eine LS-Kanalschätzung, gefolgt von einer linearen Interpolation und

einer Filterung der LOS-Komponente. Dies führt zur finalen Außerband-gestützten Kanalschätzung.

B. Datenübertragung

Zunächst werden die in Section II-A1 and Section II-A2 erhaltenen Kanalschätzungen mithilfe der in Section III und [8] beschriebenen Methoden verarbeitet. Die daraus resultierende mmWave-Kanalschätzung dient anschließend zur Vorcodierung und Kombination der Signale, basierend auf der Singular Value Decomposition (SVD), um die Datenübertragung zu optimieren.

III. DEEP LEARNING-BASIERTE KANALSCHÄTZUNG

In diesem Abschnitt präsentieren wir eine neuartige Kanalschätzungsmethode für mmWave-Systeme, die verfügbare Kanalschätzungen mit ML-Algorithmen kombiniert. Konkret nutzen wir eine CNN-basierte Kanalschätzung, die sowohl In-Band- als auch Außerband-gestützte Kanalschätzungen integriert. Der Einsatz des CNNs besteht aus zwei Phasen: dem Offline-Training zur Modellerstellung und dem Online-Einsatz zur Echtzeit-Kanalschätzung.

CNNs sind besonders gut für MIMO-Systeme geeignet, da die räumliche Anordnung der Antennen eine entscheidende Rolle spielt. Als Input für das CNN verwenden wir sowohl die In-Band-Kanalschätzung als auch die Außerband-gestützte Kanalschätzung. Darüber hinaus geben wir den geschätzten K -Faktor im Sub-6-GHz-Band sowie die Rauschvarianz im mmWave-Band als zusätzliche Eingabeparameter ein. Der K -Faktor beschreibt das Verhältnis zwischen der Leistung der dominanten LOS Komponente und der Leistung der diffusen Mehrwegekomponenten. Ein hoher K -Faktor deutet auf eine dominante LOS-Verbindung hin, während ein niedriger K -Faktor eine stärker streuende Umgebung mit überwiegend




Fig. 2. Die In-Band- und die Außerband-gestützten ML-Methoden zeigen eine vergleichbare Leistung und übertreffen die MRC-Methode über den gesamten SNR-Bereich.

nicht-LOS-Komponenten signalisiert. Die Rauschvarianz gibt die statistische Streuung des thermischen Rauschens und anderer Störquellen im mmWave-Band an. Eine hohe Rauschvarianz kann die Kanalschätzung erschweren, insbesondere bei niedrigen SNR. Das CNN gibt die geschätzte Kanalmatrix aus. Die Architektur des CNNs ist schematisch in Fig. 1 dargestellt. Jede Zwischenschicht verwendet die Rectified Linear Unit (ReLU) als Aktivierungsfunktion, gefolgt von einer Batch-Normalization (BN)-Schicht, um den Lernprozess zu stabilisieren und zu beschleunigen. Zusätzlich wird Zero Padding (ZP) eingesetzt, um die Dimensionen der Merkmalsmatrix während der Faltung beizubehalten. Die Ausgangsschicht wendet eine hyperbolische Tangenten-Aktivierungsfunktion (tanh) an, um die geschätzten Real- und Imaginärteile der Kanalmatrix zu erzeugen.

1) *Offline-Training*: Für die vorgeschlagenen Netzwerke wird eine Trainingsmenge mit L_{train} -Proben basierend auf einem spezifischen Kanalmodell in der Simulationsumgebung generiert. Um die Komplexität des Modells zu reduzieren, wird nur ein einziger zentraler OFDM-Subträger sowohl für die Eingangs- als auch für die Zieldaten berücksichtigt. Vor der Verarbeitung im Netzwerk werden die In-Band- und Außerband-gestützten Kanalschätzungen in ihre Real- und Imaginärteile getrennt. Am Ausgang werden diese Komponenten wieder kombiniert, um eine komplexwertige geschätzte Kanalmatrix zu rekonstruieren. Das Ziel des Offline-Trainings ist die Minimierung des normalisierten Kanalschätzungs-MSE. Das Netzwerk wird mit dem Adam-Optimierungsverfahren trainiert, wobei eine Batch-Größe von 64 und insgesamt 200 Trainingsepochen verwendet werden.

2) *Online-Einsatz*: Nach Abschluss des Offline-Trainings wird das trainierte CNN am Empfänger für die Online-Kanalschätzung eingesetzt. In dieser Phase wird das für einen einzelnen Subträger trainierte Netzwerk auf alle Subträger angewendet. Die trainierten Netzwerke sind robust gegenüber verschiedenen drahtlosen Kanalbedingungen, insbesondere in Bezug auf den K -Faktor und die Rauschvarianz. Daher ist




Fig. 3. Die MRC-Methode übertrefft die In-Band-CNN-Methode, aber die Außerband-gestützte CNN-Methode übertrefft die MRC-Methode bei allen SNR-Werten.

es nicht erforderlich, die Netzwerke für jedes spezifische K -Faktor- oder Rauschvarianz-Szenario neu zu trainieren, was Rechenleistung und Speicherplatz spart. Allerdings ist das CNN in Bezug auf die MIMO-Antennenkonfiguration eingeschränkt. Wenn das Netzwerk auf eine andere MIMO-Konfiguration angewendet werden soll, ist ein erneutes Training mit anderen Antennenparametern erforderlich. Zudem muss das Modell neu trainiert werden, wenn es für K -Faktor- oder Rauschvarianzwerte verwendet werden soll, die außerhalb des trainierten Bereichs liegen.

IV. SIMULATIONSBASIERTER VERGLEICH

Um die Leistung der vorgeschlagenen Methode zu bewerten, simulieren wir die normalisierte Kanalschätzungs-MSE in einem frequenzselektiven Rician-Kanal. Im Sub-6-GHz-Band betrachten wir eine Trägerfrequenz von 2.55 GHz, eine Bandbreite von 20.16 MHz und einen Subträgerabstand von 60 kHz. Für das mmWave-Band verwenden wir eine Trägerfrequenz von 25.5 GHz, eine Bandbreite von 403.2 MHz und einen Subträgerabstand von 120 kHz. Beide Bänder verwenden eine 8×8 MIMO-Konfiguration. Der Kanal wird unter Verwendung des 3rd Generation Partnership Project (3GPP) urban macro für das LOS-Szenario mit einem einstellbaren K -Faktor modelliert, wie in [10] beschrieben.

Als Nicht-ML-Baselines verwenden wir die konventionelle Kanalschätzung und das Maximal Ratio Combining (MRC), wobei weitere Details in [8] zu finden sind. Die konventionelle Kanalschätzung stützt sich ausschließlich auf die In-Band-mmWave-Kanalschätzung. Die MRC-Methode kombiniert optimal die Außerband-Kanalschätzung und die In-Band-Schätzung und ist die leistungsstärkste Methode aus [8]. Darüber hinaus zeigen wir die Leistung des In-Band-CNN, das sowohl die Außerband-Schätzung als auch den K -Faktor im Sub-6-GHz-Band ausschließt. Zusätzlich zeigen wir die Leistung für den Fall perfekter Channel State Information (CSI), um eine obere Leistungsgrenze festzulegen.

In der Simulation analysieren wir die Leistung in Abhängigkeit vom SNR. Die Ergebnisse sind in Fig. 2

TABLE I
KOMPLEXITÄTSVERGLEICH

Methode	Anzahl der Operationen
konventionelle	$1.15 \cdot 10^6$
MRC	$1.17 \cdot 10^8$
In-Band CNN	$2.43 \cdot 10^9$
Außerband-gestützte CNN	$2.56 \cdot 10^9$

und Fig. 3 für 100 Kanalrealisierungen in Form des normalisierten Kanal-MSE dargestellt. Das normalisierte Kanal-MSE nimmt mit steigendem SNR ab, unabhängig von der verwendeten Schätzmethode oder dem K -Faktor. Darüber hinaus übertreffen alle Schätzverfahren den konventionellen Nicht-ML-Ansatz über den gesamten SNR-Bereich und für beide K -Faktoren.

Bei einem K -Faktor von -20 dB (Fig. 2) zeigen die In-Band- und die Außerband-gestützten ML-Methoden eine vergleichbare Leistung und übertreffen die MRC-Methode über den gesamten SNR-Bereich. Bei einem K -Faktor von 20 dB (Fig. 3) übertrifft die MRC-Methode die In-Band-CNN-Methode, was die Bedeutung der fehlenden Außerband-Informationen verdeutlicht. Allerdings übertrifft die Außerband-gestützte CNN-Methode die MRC-Methode bei allen SNR-Werten, wodurch die intrinsischen Beziehungen zwischen den In-Band- und Außerband-Kanalschätzungen aufgedeckt werden.

Bei praktischen Online-Einsatzanwendungen ist nicht nur die Leistung der vorgeschlagenen Methoden wichtig, sondern auch ihr Rechenaufwand. Daher bewerten wir die Rechenkomplexität der vorgeschlagenen Methoden, indem wir die Anzahl der erforderlichen mathematischen Operationen berücksichtigen. Die Anzahl der erforderlichen Operationen für ein 8×8 MIMO-System ist in Tab. I zusammengefasst. Die konventionelle Kanalschätzungsmethode stützt sich ausschließlich auf eine Least-Square-Schätzung und eine Interpolation innerhalb des mmWave-Bandes. Im Gegensatz dazu erfordert die MRC-Methode eine Least-Square-Schätzung und Interpolation in beiden Bändern sowie einen entscheidenden Schritt der gemeinsamen AoD/AoA-Schätzung. Diese AoD/AoA-Schätzung erhöht die Anzahl der Operationen im Vergleich zur konventionellen Schätzung erheblich. Darüber hinaus ist die CNN-basierte Architektur diejenige mit der höchsten Anzahl von Operationen, da sie zusätzlich zu den für die MRC-Methode erforderlichen Operationen eine große Anzahl von Parametern zu berechnen hat.

V. SCHLUSSFOLGERUNG

In dieser Arbeit stellen wir eine neuartige Deep-Learning-basierte Kanalschätzungsmethode für mmWave-MIMO-Systeme vor, die Sub-6-GHz-Außerband-Informationen nutzt. Die vorgeschlagene CNN-Architektur verbessert in Kombination mit diesen Außerband-Informationen den normalisierten Kanal-MSE im Vergleich zur nicht-ML-basierten MRC-Methode.

DANKSAGUNG

Diese Arbeit wurde durch das Christian Doppler Laboratory for Digital Twin assisted AI for sustainable Radio Access Networks, Institut für Nachrichtentechnik, TU Wien, finanziert. Wir bedanken uns für die finanzielle Unterstützung durch das Bundesministerium für Arbeit und Wirtschaft, und die Nationalstiftung für Forschung, Technologie und Entwicklung sowie der Christian Doppler Forschungsgesellschaft.

REFERENCES

- [1] T. S. Rappaport, S. Sun, R. Mayzus, H. Zhao, Y. Azar, K. Wang, G. N. Wong, J. K. Schulz, M. Samimi, and F. Gutierrez, "Millimeter wave mobile communications for 5G cellular: It will work!" *IEEE Access*, vol. 1, pp. 335–349, 2013.
- [2] F. Pasic, N. Di Cicco, M. Skocaj, M. Tornatore, S. Schwarz, C. F. Mecklenbräuer, and V. Degli-Esposti, "Multi-band measurements for deep learning-based dynamic channel prediction and simulation," *IEEE Communications Magazine*, vol. 61, no. 9, pp. 98–104, 2023.
- [3] H. He, C.-K. Wen, S. Jin, and G. Y. Li, "Deep learning-based channel estimation for beam-space mmWave massive MIMO systems," *IEEE Wireless Communications Letters*, vol. 7, no. 5, pp. 852–855, 2018.
- [4] F. Pasic, L. Eller, S. Schwarz, M. Rupp, and C. F. Mecklenbräuer, "Deep learning-based mmWave MIMO channel estimation using sub-6 GHz channel information: CNN and UNet approaches," *IEEE INFOCOM 2025 - IEEE Conference on Computer Communications Workshops (INFOCOM WKSHPS)*, 2025, to be presented. [Online]. Available: <https://owncloud.tuwien.ac.at/index.php/s/828AQoql3xLSIXs>
- [5] A. Ali, N. Gonzalez-Prelcic, R. W. Heath, and A. Ghosh, "Leveraging Sensing at the Infrastructure for mmWave Communication," *IEEE Communications Magazine*, vol. 58, no. 7, pp. 84–89, 2020.
- [6] F. Pasic, M. Hofer, D. Radovic, H. Groll, S. Caban, T. Zemen, and C. F. Mecklenbräuer, "Quantifying the reproducibility of multi-band high speed wireless channel measurements," in *2023 IEEE 34th Annual International Symposium on Personal, Indoor and Mobile Radio Communications (PIMRC)*, 2023.
- [7] D. Radovic, F. Pasic, M. Hofer, T. Zemen, and C. F. Mecklenbräuer, "Stationarity of multiband channels for OTFS-based intelligent transportation systems," in *2024 18th European Conference on Antennas and Propagation (EuCAP)*, 2024.
- [8] F. Pasic, M. Hofer, M. Mussbah, S. Sangodoyin, S. Caban, S. Schwarz, T. Zemen, M. Rupp, A. F. Molisch, and C. F. Mecklenbräuer, "Millimeter wave MIMO channel estimation using sub-6 GHz out-of-band information," *IEEE Transactions on Communications*, 2024, submitted. [Online]. Available: <https://owncloud.tuwien.ac.at/index.php/s/3YP9Uq4Dxx17HeZ>
- [9] 3GPP, "Technical specification group radio access network; nr; user equipment (ue) radio transmission and reception; part 2: Range 2 standalone," 3rd Generation Partnership Project (3GPP), Technical Specification (TS) 38.101-2, 2022, version 17.5.0.
- [10] —, "Study on channel model for frequencies from 0.5 to 100 ghz," 3rd Generation Partnership Project (3GPP), Technical report (TR) 38.901, 2022, version 17.0.0.